

Relatório Técnico - AGE GAP

Nicolas de Paulo Romano

RA: 2453282

17 de junho de 2026

1 Contextualização e definição do problema

Este relatório técnico, desenvolvido para a disciplina de processamento digital de imagens, apresenta a fundamentação e a implementação de uma solução de inteligência artificial voltada para a saúde cerebral. O projeto nasce da necessidade de intervir em um cenário demográfico globalmente crítico no qual os casos de demência e da doença de Alzheimer podem triplicar em todo o mundo até o ano de 2050, segundo a Organização Mundial da Saúde.

Atualmente, o diagnóstico clínico dessas neurodegenerações enfrenta um gargalo sistêmico, sendo majoritariamente tardio e custoso. A metodologia convencional depende de um processo estritamente manual, no qual radiologistas especializados consomem horas valiosas analisando cortes de ressonância magnética na tentativa de encontrar sinais mínimos e precoces de atrofia. Esse método analógico, além de escalar os custos da saúde, é inerentemente falho por estar sujeito ao cansaço e à subjetividade humana, resultando em diagnósticos tardios que limitam a eficácia dos tratamentos.

Para transpor essa barreira tecnológica, este projeto propõe a automação computacional do cálculo do *Brain Age Gap*, de abreviatura *BAG*. O *BAG* representa a diferença quantitativa entre a idade biológica do cérebro, predita pelo modelo, e a idade cronológica real do paciente. Ao extrair essa métrica de forma automatizada, a solução entrega um biomarcador personalizado e altamente sensível, capaz de sinalizar o envelhecimento acelerado e auxiliar na previsão de quadros como Alzheimer, esquizofrenia e hipertensão crônica.

2 Base de dados

A fundação de qualquer modelo robusto de aprendizado de máquina reside na qualidade e na representatividade dos seus dados. Para garantir a capacidade de generalização inicial do algoritmo, a fase primária de testes e treinamento foi conduzida utilizando uma amostragem de 757 imagens de ressonância magnética estrutural, advindo de uma base de dados pública e multicêntrica chamada *Open Big Healthy Brains*, de abreviação *OpenBHB*.

Nesse contexto, o pipeline foi rigoroso na preparação destas amostras, utilizou-se a técnica de Morfometria Baseada em Voxel e focando exclusivamente na extração e isolamento da substância cinzenta do cérebro. Esses volumes anatômicos foram então convertidos em tensores tridimensionais no formato matemático Numpy (.npy), estabelecendo um espaço tridimensional padronizado para a alimentação da rede neural. Por fim, garantindo o rigor metodológico, o conjunto total de dados foi dividido de maneira estrita na proporção de 80% para a fase de treinamento e 20% reservados exclusivamente para a etapa de validação cruzada.

3 Arquitetura

A escolha central da engenharia do projeto consistiu no desenvolvimento de uma Rede Neural Convolutacional 3D, de abreviação *CNN*, baseada nos princípios da arquitetura *Simple*

Fully Convolutional Networks, de abreviação *SFCN*, rede cuja capacidade computacional é poderosa, mas menos custosa. Nesse sentido, as camadas Conv3d permitem processamento do tensor volumétrico inteiro de uma só vez, encontrando padrões correlacionados em todos os eixos do cérebro.

A estrutura interna da rede realiza uma extração progressiva de características ao longo de cinco blocos iniciais de convolução tridimensional. Utilizou-se *kernels* com dimensões espaciais de 3x3x3 e preenchimento simétrico padding igual a 1 para preservar a resolução original durante a passagem dos dados. O número de filtros de extração aumenta sequencialmente conforme a rede se aprofunda, indo de 32 até 256 canais. Essa transição arquitetural permite ao algoritmo evoluir do aprendizado superficial de texturas locais para o reconhecimento assertivo de padrões globais e atrofia complexas no volume cerebral.

Após cada camada convolucional, implementou-se a técnica de Normalização em Lote para estabilizar as ativações numéricas, combater a mudança de covariável interna e acelerar significativamente a convergência. Esse processo é imediatamente seguido por uma operação de *Max Pooling 3D*, que reduz as dimensões espaciais pela metade, enxugando o peso computacional em conjunto com a aplicação da função de ativação não-linear *ReLU*. No sexto bloco, um filtro convolucional de 1x1x1 atua como um gargalo estrutural, comprimindo a profundidade dos mapas de características e preparando o tensor para a aplicação de um *Average Pooling* que condensa as informações globais.

Para garantir a confiabilidade clínica do modelo, aplicou-se a técnica de Dropout 3D que força a rede a aprender caminhos redundantes e evitando o sobreajuste nos dados de treinamento. Além disso, o treinamento foi matematicamente otimizado através da função de perda de Erro Médio Absoluto, que penaliza os erros de forma linear e interpretável, combinada ao otimizador Adam com a taxa de aprendizado fixada em 0.0001.

4 Resultados

O treinamento computacionalmente intensivo da arquitetura 3D foi viabilizado através de aceleração por hardware de processamento gráfico com a plataforma Google Colab. Adicionalmente, o modelo iterou sobre o conjunto de dados de treinamento, refinando seus pesos sinápticos.

Após 25 épocas completas de processamento, a rede alcançou o seu ponto de melhor convergência, consolidando um Erro Médio Absoluto (MAE) de apenas 7.85 anos no conjunto isolado de validação. Este marco é extremamente expressivo do ponto de vista de engenharia de dados, pois prova que o algoritmo generalizou o aprendizado e a matemática da rede é executada corretamente.

5 Interface da aplicação e mercado

Todo o pipeline computacional e os pesos matemáticos treinados foram embarcados em um software web intuitivo, construído através da biblioteca visual Streamlit. O objetivo primário dessa interface é resolver a barreira de adoção técnica: transformar algoritmos complexos em uma ferramenta simples que qualquer médico ou profissional de saúde possa operar no consultório sem a necessidade de saber programar.

A jornada do usuário na plataforma ocorre através de um fluxo dinâmico e contínuo de apenas três passos: o profissional realiza o envio do exame volumétrico (.npy), digita a idade cronológica do paciente e, em segundos, recebe o laudo gerado pela IA. Este laudo calcula

instantaneamente o *Brain Age Gap* e classifica visualmente se o padrão de envelhecimento biológico daquele cérebro está em ritmo acelerado ou preservado.

No contexto mercadológico e estratégico, essa solução entra diretamente como um diferencial de alto valor em clínicas de radiologia, hospitais de ponta e planos de saúde com foco em medicina preventiva. A tecnologia concebida não tem o intuito de substituir a figura humana do médico, mas sim de atuar como uma segunda opinião ultra-rápida que amplifica a sua capacidade diagnóstica. Ao viabilizar tratamentos preventivos antes que as patologias alcancem estágios graves, o projeto não apenas promove uma drástica redução de custos sistêmicos na saúde, mas também materializa um futuro clínico onde o risco de declínio cognitivo pode ser previsto e mitigado anos antes dos primeiros sintomas aparecerem.